

Лекция 2

Винеровский и пуассоновский процессы.

Генерирование реализаций случайных процессов

Артемов А. В.
бПМИ ФКН ВШЭ

27 января 2018

1 Винеровский и пуассоновский процессы

1.1 Лирическое отступление: гауссовские векторы

Сделаю небольшое лирическое отступление и вспомним гауссовские векторы. Для этого вспомним, что такое *характеристическая функция* случайной величины и вектора.

Определение 1. Пусть ξ — случайная величина с плотностью p_ξ . Тогда её характеристической функцией называется функция $\varphi_\xi : \mathbb{R} \mapsto \mathbb{C}$, определяемая следующим образом:

$$\varphi_\xi(t) = \mathbb{E}[e^{it\xi}] = \int_{-\infty}^{+\infty} e^{itx} p_\xi(x) dx.$$

Определение 2. Пусть $\boldsymbol{\xi} = (\xi_1, \dots, \xi_n)$ — случайный вектор с совместной плотностью p_ξ . Тогда её характеристической функцией называется функция $\varphi_\xi : \mathbb{R}^n \mapsto \mathbb{C}$, определяемая следующим образом: $\varphi_\xi(\mathbf{t}) = \mathbb{E}[e^{i\langle \boldsymbol{\xi}, \mathbf{t} \rangle}]$, где $\langle \cdot, \cdot \rangle$ — скалярное произведение в \mathbb{R}^n .

По сути, характеристическая функция — это преобразование Фурье функции распределения.

Далее, из курса теории вероятности известно, что если $\xi \sim \mathcal{N}(\mu, \sigma^2)$, то

$$\varphi_\xi(t) = \exp \left\{ i\mu t - \frac{1}{2} \sigma^2 t^2 \right\}.$$

Поэтому гауссовский вектор вводят следующим образом:

Определение 3. Случайный вектор $\boldsymbol{\xi} = (\xi_1, \dots, \xi_n)$ подчиняется *многомерному нормальному распределению*, если его характеристическая функция равна

$$\varphi_\xi(\mathbf{t}) = \exp \left\{ i\langle \boldsymbol{\mu}, \mathbf{t} \rangle - \frac{1}{2} \langle \boldsymbol{\Sigma} \mathbf{t}, \mathbf{t} \rangle \right\},$$

где $\boldsymbol{\mu} \in \mathbb{R}^n$ — некоторый фиксированный вектор, а $\boldsymbol{\Sigma}$ — некоторая симметрическая и неотрицательно определённая матрица. В таком случае пишут, что $\boldsymbol{\xi} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

Это определение не очень удобно. Докажем одну теорему, которая даст несколько более удобное определение.

Теорема 1. Пусть $\xi = (\xi_1, \dots, \xi_n)$ — случайный вектор. Он будет гауссовским тогда и только тогда, когда для любого неслучайного вектора $\lambda \in \mathbb{R}^n$ $\langle \lambda, \xi \rangle$ имеет нормальное распределение.

Доказательство. Пусть $\xi \sim \mathcal{N}(\mu, \Sigma)$. Тогда посмотрим на характеристическую функцию $\langle \lambda, \xi \rangle$. Заметим, что она равна

$$\varphi_{\langle \lambda, \xi \rangle}(t) = \mathbb{E}[e^{it\langle \lambda, \xi \rangle}] = \mathbb{E}[e^{i\langle t\lambda, \xi \rangle}] = \varphi_{\xi}(t\lambda) = \exp \left\{ it\langle \mu, \lambda \rangle - \frac{t^2}{2} \langle \Sigma \lambda, \lambda \rangle \right\}.$$

Это означает, что $\langle \lambda, \xi \rangle \sim \mathcal{N}(\langle \mu, \lambda \rangle, \langle \Sigma \lambda, \lambda \rangle)$.

Теперь предположим, что $\langle \lambda, \xi \rangle$ имеет нормальное распределение для любого λ . Тогда посмотрим на характеристическую функцию ξ :

$$\varphi_{\xi}(\lambda) = \mathbb{E}[e^{i\langle \lambda, \xi \rangle}] = \varphi_{\langle \lambda, \xi \rangle}(1) = \exp \left\{ i \mathbb{E}[\langle \lambda, \xi \rangle] - \frac{1}{2} D[\langle \lambda, \xi \rangle] \right\}.$$

Теперь заметим, что

$$\mathbb{E}[\langle \lambda, \xi \rangle] = \mathbb{E} \left[\sum_{k=1}^n \lambda_k \xi_k \right] = \sum_{k=1}^n \lambda_k \mathbb{E}[\xi_k] = \langle \lambda, \mathbb{E}[\xi] \rangle, \quad (1.1)$$

$$D[\langle \lambda, \xi \rangle] = \text{cov} \left(\sum_{k=1}^n \lambda_k \xi_k, \sum_{k=1}^n \lambda_k \xi_k \right) = \sum_{i,j=1}^n \text{cov}(\xi_i, \xi_j) \lambda_i \lambda_j = \langle D[\xi] \lambda, \lambda \rangle. \quad (1.2)$$

Отсюда получаем, что $\xi \sim \mathcal{N}(\mathbb{E}[\xi], D[\xi])$. □

Теперь выпишем следствия из этой теоремы.

Следствие (Смысл параметров). Если случайный вектор $\xi \sim \mathcal{N}(\mu, \Sigma)$, то $\mu = \mathbb{E}[\xi]$, $\Sigma = D[\xi]$.

Следствие (Линейные преобразования). Любое линейное преобразование гауссовского вектора тоже является гауссовским вектором.

Теперь вспомним про плотности. У гауссовских векторов она есть не всегда.

Теорема 2 (о плотности гауссовских векторов). Пусть $\xi \sim \mathcal{N}(\mu, \Sigma)$ — n -мерный гауссовский вектор. Тогда, если Σ положительно определена, то существует плотность $p_{\xi}(\mathbf{t})$ и она равна

$$p_{\xi}(\mathbf{t}) = \frac{1}{(2\pi)^{n/2} \sqrt{\det \Sigma}} \exp \left\{ -\frac{1}{2} \langle \Sigma^{-1}(\mathbf{t} - \mu), (\mathbf{t} - \mu) \rangle \right\}.$$

Задача 1. Пусть $\mathbf{X} = (\xi, \eta)$ — гауссовский вектор, для которого:¹

$$\mathbb{E}[\mathbf{X}] = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad D[\mathbf{X}] = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}, \quad |\rho| < 1.$$

Докажите, что плотность случайного вектора \mathbf{X} равна

$$p_{\mathbf{X}}(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left(\left(\frac{x_1 - \mu_1}{\sigma_1} \right)^2 + \left(\frac{x_2 - \mu_2}{\sigma_2} \right)^2 - 2\rho \frac{x_1 - \mu_1}{\sigma_1} \frac{x_2 - \mu_2}{\sigma_2} \right) \right\}$$

¹Несложно понять, что ρ есть коэффициент корреляции между ξ и η .

Порой хочется сказать, что любой вектор, состоящий из нормальных случайных величин, является гауссовским. Но это неверно.

Пример 1. Пусть ξ_1 и ξ_2 — это независимые стандартные нормальные случайные величины. Построим случайный вектор (X_1, X_2) следующим образом:

$$(X_1, X_2) = \begin{cases} (\xi_1, |\xi_2|), & \xi_1 \geq 0 \\ (\xi_1, -|\xi_2|), & \xi_1 < 0 \end{cases}$$

Данный случайный вектор не будет гауссовским (почему?).

У гауссовских векторов есть одно уникальное свойство, связанное с некоррелированностью.

Теорема 3. Пусть ξ — гауссовский вектор. Тогда его компоненты независимы тогда и только тогда, когда они некоррелированы.

Вопрос: допустим, что у нас есть вектор, состоящий из некоррелированных нормальных случайных величин. Можно ли сказать, что он гауссовский? Оказывается, что нет.

Пример 2. Пусть $X \sim \mathcal{N}(0, 1)$ и $c \geq 0$. Построим по ней новую случайную величину Y следующим образом:

$$Y = \begin{cases} X, & |X| \leq c \\ -X, & |X| > c \end{cases}$$

Оказывается, что $Y \sim \mathcal{N}(0, 1)$. Тогда $\text{cov}(X, Y) = \mathbb{E}[XY]$, что, в свою очередь, равно $\mathbb{E}[X^2 \mathbb{I}\{|X| \leq c\}] - \mathbb{E}[X^2 \mathbb{I}\{|X| > c\}]$. Что мы можем сказать про ковариацию?

- Она является непрерывной функцией от c .
- Если $c = 0$, то $\text{cov}(X, Y) = -1$, а если $c = +\infty$, то $\text{cov}(X, Y) = 1$.

В таком случае можно сказать, что есть c такая, что $\text{cov}(X, Y) = 0$. Зафиксируем её. Можно ли сказать, что (X, Y) — это гауссовский вектор? Увы, но нет. Если бы это было так, то X и Y были бы независимы. Но $\mathbb{P}(X > c, Y > c) = 0 \neq \mathbb{P}(X > c) \mathbb{P}(Y > c)$.

Теперь расскажем два факта, которые могут понадобиться в дальнейшем и связаны с нормальным распределением.

Пример 3. Пусть (ξ, η) — случайный вектор с совместной плотностью

$$p_{\xi, \eta}(x, y) = C \exp\{-(1+x^2)(1+y^2)\}, \text{ где } C = \iint_{\mathbb{R}^2} \exp\{-(1+x^2)(1+y^2)\} dx dy$$

Попробуем найти условную плотность $p_{\xi|\eta}(x | y)$. Сразу же заметим, что процесс аналогичен для $p_{\eta|\xi}(y | x)$. Для этого найдём плотность η :

$$\begin{aligned} p_{\eta}(y) &= \int_{-\infty}^{+\infty} C e^{-(1+x^2)(1+y^2)} dx = C e^{-(1+y^2)} \int_{-\infty}^{+\infty} e^{-x^2(1+y^2)} dx = \\ &= \frac{C e^{-(1+y^2)}}{\sqrt{y^2+1}} \int_{-\infty}^{+\infty} e^{-u^2} du = \frac{C \sqrt{\pi} e^{-(1+y^2)}}{\sqrt{y^2+1}}. \end{aligned}$$

Теперь несложно посчитать условную плотность:

$$p_{\xi|\eta}(x | y) = \frac{g(x, y)}{p_{\eta}(y)} = \frac{\sqrt{y^2+1}}{\sqrt{\pi}} e^{-x^2(1+y^2)} = \frac{1}{\sqrt{2\pi\sigma_y^2}} e^{-\frac{x^2}{2\sigma_y^2}}, \text{ где } \sigma_y^2 = \frac{1}{2+2y^2}.$$

Из математической статистики вам известны такие понятия, как оценки. Следующая теорема в некоторой степени связана с ними, но это станет ясней позднее, когда дело дойдёт до фильтров Калмана.

Теорема 4 (о нормальной корреляции, одномерный случай). Пусть (ξ, η) — двумерный гауссовский вектор. Тогда

$$E[\eta | \xi] = E[\eta] + \frac{\text{cov}(\xi, \eta)}{D[\xi]}(\xi - E[\xi]), \quad (1.3)$$

$$\Delta = E[(\eta - E[\eta | \xi])^2] = D[\eta] - \frac{\text{cov}^2(\xi, \eta)}{D[\xi]}. \quad (1.4)$$

Доказательство. Докажем эту теорему в лоб. Для этого посчитаем условную плотность $p_{\eta|\xi}(y | x)$. Формула для совместной плотности была выведена в задаче 1. Пользуясь теми же обозначениями, получим (проверьте!), что

$$p_{\eta|\xi}(y | x) = \frac{1}{\sqrt{2\pi\sigma_2^2(1-\rho^2)}} \exp \left\{ -\frac{1}{2\sigma_2^2(1-\rho^2)} \left(y - \mu_2 - \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1) \right)^2 \right\}.$$

Из этого можно сделать следующий вывод:

$$(\eta | \xi = x) \sim \mathcal{N} \left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2) \right) \implies E[\eta | \xi] = \mu_2 + \rho \frac{\sigma_2}{\sigma_1}(\xi - \mu_1).$$

Заменяя, получим первую часть утверждения. Для доказательства второго утверждения подставим полученный результат и раскроем скобки как квадрат разности:

$$\begin{aligned} \Delta &= E \left[\left(\eta - E[\eta] - \frac{\text{cov}(\xi, \eta)}{D[\xi]}(\xi - E[\xi]) \right)^2 \right] = E[(\eta - E[\eta])^2] - \\ &\quad - 2 \frac{\text{cov}(\xi, \eta)}{D[\xi]} E[(\eta - E[\eta])(\xi - E[\xi])] + \frac{\text{cov}^2(\xi, \eta)}{D^2[\xi]} E[(\xi - E[\xi])^2] = D[\eta] - \frac{\text{cov}^2(\xi, \eta)}{D[\xi]}. \quad \square \end{aligned}$$

У данной теоремы есть многомерное обобщение.

Теорема 5 (о нормальной корреляции, общий случай). Пусть $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ — n -мерный гауссовский вектор. Сделаем следующее разбиение:

$$\mathbf{X} = \begin{pmatrix} \boldsymbol{\xi} \\ \boldsymbol{\eta} \end{pmatrix} \text{ с размерами } \begin{pmatrix} q \times 1 \\ (n - q) \times 1 \end{pmatrix}$$

Соответственным образом вводятся разбиения матожидания и матрицы ковариаций:

$$\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix} \text{ с размерами } \begin{pmatrix} q \times 1 \\ (n - q) \times 1 \end{pmatrix} \quad (1.5)$$

$$\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix} \text{ с размерами } \begin{pmatrix} q \times q & q \times (n - q) \\ (n - q) \times q & (n - q) \times (n - q) \end{pmatrix} \quad (1.6)$$

Тогда верны следующие формулы:

$$E[\boldsymbol{\xi} | \boldsymbol{\eta}] = \boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1}(\boldsymbol{\eta} - \boldsymbol{\mu}_2), \quad (1.7)$$

$$\Delta = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21}. \quad (1.8)$$

Доказательство. Для начала найдём линейную комбинацию $\delta = \xi + A\eta$ такую, что она некоррелирована (а следовательно, и независима) с η . Для этого распишем корреляцию:

$$\text{cov}(\delta, \eta) = \text{cov}(\xi, \eta) + \text{cov}(A\eta, \eta) = \text{cov}(\xi, \eta) + A D[\eta] = \Sigma_{12} + A \Sigma_{22} \implies A = -\Sigma_{12} \Sigma_{22}^{-1}.$$

Отсюда получаем, что

$$\begin{aligned} E[\xi | \eta] &= E[\delta - A\eta | \eta] = E[\delta | \eta] - E[A\eta | \eta] = E[\delta] - A\eta = \mu_1 + A(\mu_2 - \eta) = \\ &= \mu_1 + \Sigma_{12} \Sigma_{22}^{-1}(\eta - \mu_2). \end{aligned}$$

Теперь посмотрим на то, как себя ведёт Δ . Как известно, по формуле полной вероятности:

$$\Delta = E[(\xi - E[\xi | \eta])^2] = E[E[(\xi - E[\xi | \eta])^2 | \eta]] = E[D[\xi | \eta]].$$

Теперь посмотрим на условную дисперсию:

$$D[\xi | \eta] = D[\delta - A\eta | \eta] = D[\delta | \eta] + D[A\eta | \eta] - \text{cov}(\delta, A\eta | \eta) - \text{cov}(A\eta, \delta | \eta).$$

Как известно, матожидание вектора, умноженного на матрицу слева/справа, равно матожиданию вектора, умноженного на эту же матрицу слева/справа, а условная дисперсия случайной величины, не зависящей от условия, равна обычной дисперсии. Тогда это равно

$$D[\delta | \eta] + A D[\eta | \eta] A^\top - \text{cov}(\delta, \eta | \eta) A^\top - A \text{cov}(\eta, \delta | \eta) = D[\delta | \eta] = D[\delta].$$

Осталось посчитать эту дисперсию. Для этого распишем дисперсию суммы, пользуясь свойствами матриц Σ_{ij} :

$$\begin{aligned} D[\delta] &= D[\xi + A\eta] = D[\xi] + D[A\eta] + \text{cov}(\xi, A\eta) + \text{cov}(A\eta, \xi) = \\ &= D[\xi] + A D[\eta] A^\top + \text{cov}(\xi, \eta) A^\top + A \text{cov}(\eta, \xi) = \\ &= \Sigma_{11} + (-\Sigma_{12} \Sigma_{22}^{-1}) \Sigma_{22} (-\Sigma_{12} \Sigma_{22}^{-1})^\top + \Sigma_{12} (-\Sigma_{12} \Sigma_{22}^{-1})^\top + (-\Sigma_{12} \Sigma_{22}^{-1}) \Sigma_{21} = \\ &= \Sigma_{11} + \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{22} \Sigma_{22}^{-1} \Sigma_{21} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} = \\ &= \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \end{aligned}$$

Так как матожидание константы есть сама константа, то $\Delta = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$. \square

1.2 Примеры случайных процессов

Наше небольшое введение закончилось. Теперь можно посмотреть на несколько основных примеров случайных процессов.

1.2.1 Гауссовский и винеровский процессы

Многие процессы, которые попадают на практике, обладают так называемыми независимыми приращениями. Что это значит?

Определение 4. Пусть $X = (X_t)_{t \geq 0}$ — некоторый случайный процесс. Будем говорить, что X есть процесс с независимыми приращениями, если для любых $t_0, t_1, \dots, t_n \in T$ таких, что $0 = t_0 < t_1 < \dots < t_n$ случайные величины $X_{t_0}, X_{t_1} - X_{t_0}, \dots, X_{t_n} - X_{t_{n-1}}$ независимы в совокупности.

В 1827 году Роберт Броун открыл движение пылевых зёрен в жидкости. Исследуя пыльцу под микроскопом, он установил, что в растительном соке плавающие пылевые зёрна двигаются совершенно хаотически зигзагообразно во все стороны. В дальнейшем это хаотическое движение назвали *броуновским*. Для его математического описания используется так называемый *винеровский процесс*. Как он вводится?

Определение 5. Случайный процесс $B = (B_t)_{t \geq 0}$ называется винеровским, если для него выполнены следующие условия:

1. $B_0 = 0$ почти наверное.
2. B — процесс с независимыми приращениями.
3. $B_t - B_s \sim \mathcal{N}(0, t - s)$ для любых $0 \leq s < t < +\infty$.
4. B имеет непрерывные почти наверное траектории, то есть с вероятностью 1 B_t непрерывна, как функция от t .

Обычно наряду с винеровскими процессами вводят *гауссовские процессы*.

Определение 6. Случайный процесс $X = (X_t)_{t \in T}$ называется гауссовским, если все его конечномерные функции распределения являются гауссовскими, то есть задают гауссовский вектор.

Свойство 1. Гауссовский процесс однозначно определяется своим математическим ожиданием и ковариационной функцией.

Пример 4. Оказывается, что винеровский процесс является гауссовским. Действительно, возьмём произвольные t_0, t_1, \dots, t_n таким образом, что $0 = t_0 < t_1 < \dots < t_n$. Как известно, у винеровского процесса независимые приращения. Следовательно, $B_{t_0}, B_{t_1} - B_{t_0}, \dots, B_{t_n} - B_{t_{n-1}}$ независимы в совокупности и образуют гауссовский вектор. Теперь поймём, какие распределения имеют $B_{t_0}, B_{t_1}, \dots, B_{t_n}$. Для этого заметим, что

$$\begin{pmatrix} B_{t_0} \\ B_{t_1} \\ B_{t_2} \\ \vdots \\ B_{t_n} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 1 & 1 & 0 & \dots & 0 \\ 1 & 1 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & 1 & \dots & 1 \end{pmatrix} \begin{pmatrix} B_{t_0} \\ B_{t_1} - B_{t_0} \\ B_{t_2} - B_{t_1} \\ \vdots \\ B_{t_n} - B_{t_{n-1}} \end{pmatrix}$$

Следовательно, $B_{t_i} \sim \mathcal{N}(0, t_i)$ и они образуют гауссовский вектор.

Из этого сразу же получаем, что $\mathbb{E}[B_t] = 0$. Теперь покажем, что $R_B(t_1, t_2) = \min(t_1, t_2)$. Без ограничения общности будем считать, что $t_1 < t_2$. Тогда

$$R_B(t_1, t_2) = \mathbb{E}[B_{t_1} B_{t_2}] = \mathbb{E}[B_{t_1} ((B_{t_2} - B_{t_1}) + B_{t_1})] = \mathbb{E}[B_{t_1} (B_{t_2} - B_{t_1})] + \mathbb{E}[B_{t_1}^2].$$

Так как B_{t_1} и $B_{t_2} - B_{t_1}$ независимы, то $\mathbb{E}[B_{t_1} (B_{t_2} - B_{t_1})] = \mathbb{E}[B_{t_1}] \mathbb{E}[B_{t_2} - B_{t_1}] = 0$. Тем самым мы получаем, что $R_B(t_1, t_2) = t_1$.

1.2.2 Процесс Орнштейна-Уленбека

Этот процесс пошёл из теории стохастических дифференциальных уравнений. Пусть $B = (B_t)_{t \geq 0}$ — винеровский процесс. Построим по нему новый процесс $X = (X_t)_{t \geq 0}$ по следующему правилу: $X_t = e^{-t} B_{e^{2t}}$. Полученный процесс называется *процессом Орнштейна-Уленбека*. Каковы его свойства?

Свойство 2. $E[X_t] = 0$, $R_X(t, s) = e^{-|t-s|}$.

Доказательство. Первая часть очевидна: $E[X_t] = E[e^{-t} B_{e^{2t}}] = 0$. Теперь рассмотрим ковариационную функцию:

$$R_X(t, s) = E[X_t X_s] = e^{-(s+t)} E[B_{e^{2t}} B_{e^{2s}}] = e^{2\min(t,s) - (s+t)} = e^{-|t-s|}. \quad \square$$

Свойство 3. Процесс Орнштейна-Уленбека является гауссовским.

Доказательство. Без ограничения общности зафиксируем числа $t_1 < t_2 < \dots < t_n$. Рассмотрим случайный вектор $(X_{t_1}, \dots, X_{t_n})$. Как он устроен? Распишем последний член:

$$\begin{aligned} X_{t_n} &= e^{-t_n} B_{e^{2t_n}} = e^{-t_n} (B_{e^{2t_n}} - B_{e^{2t_{n-1}}}) + e^{-t_n} B_{e^{2t_{n-1}}} = \dots = \\ &= e^{-t_n} \sum_{k=1}^{n-1} (B_{e^{2t_{k+1}}} - B_{e^{2t_k}}) + e^{-t_n} B_{e^{2t_1}} \end{aligned}$$

Далее, нам известно, что $B_{e^{2t_1}}, B_{e^{2t_2}} - B_{e^{2t_1}}, \dots, B_{e^{2t_n}} - B_{e^{2t_{n-1}}}$ независимы в совокупности и имеют следующие распределения:

$$B_{e^{2t_1}} \sim \mathcal{N}(0, e^{2t_1}), \quad B_{e^{2t_k}} - B_{e^{2t_{k-1}}} \sim \mathcal{N}(0, e^{2t_k} - e^{2t_{k-1}}).$$

Осталось заметить, что

$$\begin{pmatrix} X_{t_1} \\ X_{t_2} \\ X_{t_3} \\ \vdots \\ X_{t_n} \end{pmatrix} = \begin{pmatrix} e^{-t_1} & 0 & 0 & \dots & 0 \\ e^{-t_2} & e^{-t_2} & 0 & \dots & 0 \\ e^{-t_3} & e^{-t_3} & e^{-t_3} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ e^{-t_n} & e^{-t_n} & e^{-t_n} & \dots & e^{-t_n} \end{pmatrix} \begin{pmatrix} B_{e^{2t_1}} \\ B_{e^{2t_2}} - B_{e^{2t_1}} \\ B_{e^{2t_3}} - B_{e^{2t_2}} \\ \vdots \\ B_{e^{2t_n}} - B_{e^{2t_{n-1}}} \end{pmatrix}$$

Отсюда получаем, что $(X_{t_1}, \dots, X_{t_n})$ — действительно гауссовский вектор. \square

Теперь посчитаем совместную плотность такого вектора. Для этого выпишем совместную плотность $\xi = (B_{e^{2t_1}}, B_{e^{2t_2}} - B_{e^{2t_1}}, \dots, B_{e^{2t_n}} - B_{e^{2t_{n-1}}})$. Так как компоненты независимы, то она равна произведению плотностей каждой компоненты:

$$p_\xi(x_1, \dots, x_n) = \frac{1}{\sqrt{2\pi}e^{t_1}} \exp\left\{-\frac{x_1^2}{2e^{2t_1}}\right\} \prod_{k=2}^n \frac{1}{\sqrt{2\pi(e^{2t_k} - e^{2t_{k-1}})}} \exp\left\{-\frac{x_k^2}{2(e^{2t_k} - e^{2t_{k-1}})}\right\}$$

Теперь выразим компоненты вектора ξ через компоненты вектора $\eta = (X_1, X_2, \dots, X_n)$:

$$\begin{cases} B_{e^{2t_1}} = e^{t_1} X_1 \\ B_{e^{2t_2}} = e^{t_2} X_2 \\ \dots \\ B_{e^{2t_n}} = e^{t_n} X_n \end{cases} \implies \begin{cases} B_{e^{2t_1}} = e^{t_1} X_1 \\ B_{e^{2t_2}} - B_{e^{2t_1}} = e^{t_2} X_2 - e^{t_1} X_1 \\ \dots \\ B_{e^{2t_n}} - B_{e^{2t_{n-1}}} = e^{t_n} X_n - e^{t_{n-1}} X_{n-1} \end{cases}$$

В матричном виде это можно записать следующим образом:

$$\begin{pmatrix} B_{e^{2t_1}} \\ B_{e^{2t_2}} - B_{e^{2t_1}} \\ B_{e^{2t_3}} - B_{e^{2t_2}} \\ \vdots \\ B_{e^{2t_n}} - B_{e^{2t_{n-1}}} \end{pmatrix} = \begin{pmatrix} e^{t_1} & 0 & 0 & \dots & 0 \\ -e^{t_1} & e^{t_2} & 0 & \dots & 0 \\ 0 & -e^{t_2} & e^{t_3} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & e^{t_n} \end{pmatrix} \begin{pmatrix} X_{t_1} \\ X_{t_2} \\ X_{t_3} \\ \vdots \\ X_{t_n} \end{pmatrix}$$

Несложно понять, что матрица перехода служит матрицей Якоби и её определитель равен $e^{t_1 + \dots + t_n}$. Следовательно,

$$p_{\eta}(x_1, \dots, x_n) = e^{t_1 + \dots + t_n} p_{\xi}(e^{t_1}x_1, e^{t_2}x_2 - e^{t_1}x_1, \dots, e^{t_n}x_n - e^{t_{n-1}}x_{n-1}).$$

Подставляя, получаем, что

$$\begin{aligned} p_{\eta}(x_1, \dots, x_n) &= \frac{e^{t_1}}{\sqrt{2\pi}e^{t_1}} \exp\left\{-\frac{x_1^2 e^{2t_1}}{2e^{2t_1}}\right\} \prod_{k=2}^n \frac{e^{t_k}}{\sqrt{2\pi}(e^{2t_k} - e^{2t_{k-1}})} \exp\left\{-\frac{(e^{t_k}x_k - e^{t_{k-1}}x_{k-1})^2}{2(e^{2t_k} - e^{2t_{k-1}})}\right\} = \\ &= \left(2\pi \prod_{k=2}^n (1 - e^{2(t_{k-1} - t_k)})\right)^{-\frac{1}{2}} \exp\left\{-\frac{x_1^2}{2} - \frac{1}{2} \sum_{k=2}^n \frac{(x_k - x_{k-1}e^{t_{k-1}-t_k})^2}{1 - e^{2(t_{k-1}-t_k)}}\right\}. \end{aligned}$$

1.2.3 Пуассоновский процесс

Перейдём к одному из самых простых для исследования процессов — к *пуассоновскому потоку*.

Определение 7. Случайный процесс $X = (X_t)_{t \geq 0}$ называется пуассоновским потоком с *интенсивностью* λ , если он удовлетворяет трём условиям:

1. $X_0 = 0$ почти наврное.
2. X — процесс с независимыми приращениями.
3. Для всех $0 \leq s < t < +\infty$ $X_t - X_s \sim \text{Pois}(\lambda(t-s))$, то есть для любого $n \in \mathbb{Z}_+$

$$P(X_t - X_s = n) = \frac{(\lambda(t-s))^n}{n!} e^{-\lambda(t-s)}.$$

Теперь построим пример такого процесса. Для этого вспомним процесс восстановления, описанный в примере ??.

Пусть для любого натурального n T_n — это iid случайные величины с распределением $\text{Exp}(\lambda)$, то есть их плотность равна $p(z) = \lambda e^{-\lambda z} \mathbf{I}\{z \geq 0\}$. Далее, $S_n = T_1 + \dots + T_n$, а для любого $t \geq 0$

$$N_t = \sum_{n=1}^{\infty} \mathbf{I}\{S_n \leq t\} = \#\{n \in \mathbb{N} : S_n < t\}.$$

Полученный случайный процесс обладает некоторыми интересными свойствами.

Свойство 4. Для любого $t > 0$ $N_t \sim \text{Pois}(\lambda t)$.

Доказательство. Понятно, что N_t принимает значения в \mathbb{Z}_+ . Следовательно, достаточно показать, что вероятности принять нужное значение будут именно такими, какими они должны быть.

Пусть $n = 0$. Тогда

$$P(N_t = 0) = P(T_1 > t) = \int_t^{\infty} \lambda e^{-\lambda x} dx = e^{-\lambda t} \int_t^{\infty} \lambda e^{-\lambda(x-t)} dx = e^{-\lambda t} = \frac{(\lambda t)^0}{0!} e^{-\lambda t}.$$

Теперь посмотрим на вероятность события $N_t = n$. Она равна

$$P(N_t = n) = P(N_t \geq n) - P(N_t \geq n+1) = P(S_n \leq t) - P(S_{n+1} \leq t).$$

Для того, чтобы посчитать полученные вероятности, вспомним один факт: сумма n iid случайных величин с распределением $\text{Exp}(\lambda)$ имеет гамма-распределение $\Gamma(1/\lambda, n)$ с плотностью

$$p_n(x) = \frac{\lambda^n x^{n-1} e^{-\lambda x}}{\Gamma(n)} = \frac{\lambda^n x^{n-1} e^{-\lambda x}}{(n-1)!}.$$

Тогда эта вероятность равна

$$P(N_t = n) = \int_0^t \left(\frac{\lambda^n x^{n-1} e^{-\lambda x}}{(n-1)!} - \frac{\lambda^{n+1} x^n e^{-\lambda x}}{n!} \right) dx = \int_0^t \left(\frac{\lambda^n x^{n-1} e^{-\lambda x}}{n!} \right)' dx = \frac{(\lambda t)^n}{n!} e^{-\lambda t}. \quad \square$$

Следствие. $E[N_t] = \lambda t$, $D[N_t] = \lambda t$.

Свойство 5. $N = (N_t)_{t \geq 0}$ — это пуассоновский поток с интенсивностью λ .

Доказательство. Для начала покажем, что $N_0 = 0$ почти наверное. Действительно, если $N_0 \neq 0$, то $T_1 = 0$, что происходит с нулевой вероятностью. Тем самым $N_0 = 0$ почти наверное.

Теперь докажем, что $(N_t)_{t \geq 0}$ удовлетворяет двум последним свойствам. Для этого заметим, что

$$\begin{pmatrix} S_1 \\ S_2 \\ S_3 \\ \vdots \\ S_n \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 1 & 1 & 0 & \dots & 0 \\ 1 & 1 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & 1 & \dots & 1 \end{pmatrix} \begin{pmatrix} T_1 \\ T_2 \\ T_3 \\ \vdots \\ T_n \end{pmatrix}$$

Так как у матрицы единичный определитель и замена линейна, то

$$p_{S_1, \dots, S_n}(x_1, x_2, \dots, x_n) = p_{T_1, \dots, T_n}(x_1, x_2 - x_1, \dots, x_n - x_{n-1})$$

Пользуясь независимостью T_n , получаем, что

$$p_{S_1, \dots, S_n}(x_1, x_2, \dots, x_n) = \lambda e^{-\lambda x_1} \prod_{k=2}^n \lambda e^{-\lambda(x_k - x_{k-1})} I\{x_k - x_{k-1} \geq 0\}$$

После преобразования получаем, что

$$p_{S_1, \dots, S_n}(x_1, x_2, \dots, x_n) = \lambda^n e^{-\lambda x_n} I\{x_n \geq x_{n-1} \geq \dots \geq x_1 \geq 0\}$$

Дальше, зафиксируем какие-либо числа $0 \leq t_1 < t_2 < \dots < t_n$, $k_1 \leq k_2 \leq \dots \leq k_n$ и посмотрим на следующую вероятность:

$$P(N_{t_1} = k_1, N_{t_2} - N_{t_1} = k_2 - k_1, \dots, N_{t_n} - N_{t_{n-1}} = k_n - k_{n-1})$$

Поймём, как связать это с S_n . Для этого поймём, как устроено первое условие. Оно означает, что $S_1, \dots, S_{k_1} \leq t_1$, а $S_{k_1+1} > t_1$. Аналогично, получаем, что эта вероятность равна

$$P(S_1, \dots, S_{k_1} \in (0, t_1], S_{k_1+1}, \dots, S_{k_2} \in (t_1, t_2], \dots, S_{k_{n-1}+1}, \dots, S_{k_n} \in (t_{n-1}, t_n], S_{k_n+1} > t_n)$$

Пользуясь плотностью случайного вектора из S_k , запишем это в виде интеграла:

$$\int \dots \int \lambda^{k_n+1} e^{-\lambda x_{k_n+1}} I\{x_{k_n+1} \geq x_{k_n} \geq \dots \geq x_1 \geq 0\} dx_1 \dots dx_{k_n} dx_{k_n+1}$$

$0 < x_1, \dots, x_{k_1} \leq t_1$
 $t_1 < x_{k_1+1}, \dots, x_{k_2} \leq t_2$
 \dots
 $t_{n-1} < x_{k_{n-1}+1}, \dots, x_{k_n} \leq t_n$
 $x_{k_n+1} > t_n$

Разобьём его в произведение интегралов, положив $k_0 = t_0 = 0$:

$$\lambda^{k_n} \int_{t_n}^{\infty} \lambda e^{-\lambda x_{k_n+1}} dx_{k_n+1} \prod_{j=1}^n \int_{t_{j-1} < x_{k_{j-1}+1} \leq \dots \leq x_{k_j} \leq t_j} dx_{k_{j-1}+1} \dots dx_{k_j}$$

Интегралы в произведении берутся достаточно просто: это объём симплекса. Рассуждая по аналогии с трёхмерным случаем, получаем, что интеграл равен

$$\lambda^{k_n} e^{-\lambda t_n} \prod_{j=1}^n \frac{(t_j - t_{j-1})^{k_j - k_{j-1}}}{(k_j - k_{j-1})!}$$

Теперь сделаем подгон: заметим, что

$$k_n = k_n - k_0 = \sum_{j=1}^n (k_j - k_{j-1}), \quad t_n = t_n - t_0 = \sum_{j=1}^n (t_j - t_{j-1})$$

Тогда интеграл равен

$$\prod_{j=1}^n \frac{(\lambda(t_j - t_{j-1}))^{k_j - k_{j-1}}}{(k_j - k_{j-1})!} e^{-\lambda(t_j - t_{j-1})}.$$

Какая красота. Отсюда мы сразу получаем оба свойства. Тем самым процесс восстановления для экспоненциального распределения является пуассоновским потоком с интенсивностью λ . \square

Следующее свойство связано с понятием стационарных приращений.

Определение 8. Случайный процесс $X = (X_t)_{t \geq 0}$ имеет *стационарные приращения*, если для любых $0 \leq t_0 < t_1 < t_2 < \dots < t_n < +\infty$ и $\forall h \geq 0$

$$(X_{t_1+h} - X_{t_0+h}, \dots, X_{t_n+h} - X_{t_{n-1}+h}) \stackrel{d}{=} (X_{t_1} - X_{t_0}, \dots, X_{t_n} - X_{t_{n-1}}).$$

Свойство 6. Пуассоновский поток имеет стационарные приращения.

Доказательство. Следует из того, что $X_{a+h} - X_{b+h} \sim \text{Pois}(a-b) \sim X_a - X_b$ и приращения независимы. \square

Свойство 7. Пусть N^1, \dots, N^k — независимые пуассоновские потоки с интенсивностями $\lambda_1, \dots, \lambda_k$. Тогда случайный процесс $N_t = N_t^1 + \dots + N_t^k$ — это пуассоновский процесс с интенсивностью $\lambda = \lambda_1 + \dots + \lambda_k$.

1.3 Стационарность случайных процессов

На практике часто попадаются процессы, которые неизменны во времени. Их принято называть *стационарными*. Это понятие было введено и для случайных процессов, хоть и не в одной ипостаси.

Буквальный перевод вышесказанного на математический язык даёт *стационарность в узком смысле*.

Определение 9. Случайный процесс $X = (X_t)_{t \in T}$ называется *сильно стационарным* (strong sense stationary, SSS, стационарным в узком смысле), если для любого натурального n , любых индексов $t_1, t_2, \dots, t_n \in T$ и любого сдвига $h \geq 0$

$$F_{t_1+h, \dots, t_n+h}(x_1, \dots, x_n) = F_{t_1, \dots, t_n}(x_1, \dots, x_n).$$

Пример 5. Последовательность iid случайных величин — это стационарная в узком смысле случайная последовательность.

Пример 6. Винеровский процесс не является стационарным в узком смысле. Действительно, пусть $n = 1$ и $h > 0$. Тогда $B_t \sim \mathcal{N}(0, t)$, а $B_{t+h} \sim \mathcal{N}(0, t+h)$ и $F_{t+h}(x) \neq F_t(x)$.

У стационарных в узком смысле процессов есть одно полезное свойство. Но у него есть требование — процесс должен быть второго порядка. Что это значит?

Определение 10. Случайный процесс $(X_t)_{t \in T}$ называется *процессом второго порядка*, если $E[X_t^2]$ конечно для всех t (то есть это ограниченная функция от t).

Свойство 1. Если $(X_t)_{t \in T}$ — стационарный в узком смысле процесс второго порядка, то

1. $m(t) = \mu = \text{const}$, $D(t) = \sigma^2 = \text{const}$.
2. Для любых $t_1, t_2, h \in T$ $R_X(t_1, t_2) = R_X(t_1 + h, t_2 + h)$.

Данное свойство очевидным образом следует из определения стационарного в узком смысле процесса и того, что матожидание, дисперсия и ковариация конечны. Последнее свойство позволяет свести ковариационную функцию к одному аргументу: $R_X(t_1, t_2) = R_X(0, t_2 - t_1) \equiv R_X(t_2 - t_1)$.

Вообще говоря, выполнение этих трёх свойств — это тоже в некоторой степени стационарность. Только в широком смысле.

Определение 11. Случайный процесс $X = (X_t)_{t \in T}$ называется *слабо стационарным* (стационарным в широком смысле, wide sense stationary, WSS, ковариационно стационарным, стационарным второго порядка),² если выполнены следующие условия:

1. $m(t) = \mu = \text{const}$, $D(t) = \sigma^2 = \text{const}$.
2. Для любых $t_1, t_2, h \in T$ $R_X(t_1, t_2) = R_X(t_1 + h, t_2 + h)$.

Обычно сильная и слабая стационарности идут вместе (если это не так, то что-то пошло не туда). Например, если семейство конечномерных функций распределения полностью задаётся матожиданием и ковариационной функцией, то сильная стационарность равносильна слабой стационарности.

У ковариационной функции стационарного в широком смысле случайного процесса есть несколько свойств:

²Название ковариационной стационарности появилось из-за того, что ковариационная функция зависит только от разности индексов. Стационарность второго порядка же означает постоянство второго момента.

1. Она неотрицательна в нуле: $R_X(0) = R_X(t, t) = D(t) = \sigma^2 \geq 0$.
2. Она чётна: $R_X(-\tau) = R_X(0, -\tau) = R_X(-\tau, 0) = R_X(0, \tau) = R_X(\tau)$.
3. Она ограничена по модулю дисперсией. Действительно, по неравенству Коши-Буняковского-Шварца $|R_X(\tau)| = |R_X(t, t + \tau)| = |\text{cov}(X_t, X_{t+\tau})| \leq \sqrt{D[X_t] D[X_{t+\tau}]} = \sigma^2$.
4. Аналог неотрицательной определённости: для любого натурального n , любого неслучайного вектора (z_1, \dots, z_n) и любого набора индексов t_1, \dots, t_n

$$\sum_{i,j=1}^n R_X(t_i - t_j) z_i z_j \geq 0.$$

5. Если $R_X(\tau)$ непрерывна в нуле, то она непрерывна для любого τ .

Доказательство. Пусть $\xi_t = X_t - E[X_t]$. Пользуясь этим обозначением, распишем разность ковариационных функций.

$$\begin{aligned} R_X(t_1 + h_1, t_2 + h_2) - R_X(t_1, t_2) &= E[\xi_{t_1+h_1} \xi_{t_2+h_2} - \xi_{t_1} \xi_{t_2}] = \\ &= E[\xi_{t_1+h_1} (\xi_{t_2+h_2} - \xi_{t_2})] + E[(\xi_{t_1+h_1} - \xi_{t_1}) \xi_{t_2}] \end{aligned}$$

Далее, по неравенству треугольника:

$$|R_X(t_1 + h_1, t_2 + h_2) - R_X(t_1, t_2)| \leq |E[\xi_{t_1+h_1} (\xi_{t_2+h_2} - \xi_{t_2})]| + |E[(\xi_{t_1+h_1} - \xi_{t_1}) \xi_{t_2}]|$$

Теперь воспользуемся неравенством Коши-Буняковского-Шварца:

$$|R_X(t_1 + h_1, t_2 + h_2) - R_X(t_1, t_2)| \leq \sqrt{E[\xi_{t_1+h_1}^2] E[(\xi_{t_2+h_2} - \xi_{t_2})^2]} + \sqrt{E[(\xi_{t_1+h_1} - \xi_{t_1})^2] E[\xi_{t_2}^2]}$$

Осталось показать, что эта сумма стремится к нулю. Покажем, что первый член уходит в ноль (второй рассматривается аналогично). Действительно, по непрерывности $R_X(t, t)$

$$\begin{aligned} E[(\xi_{t_2+h_2} - \xi_{t_2})^2] &= E[\xi_{t_2+h_2}^2] - 2E[\xi_{t_2+h_2} \xi_{t_2}] + E[\xi_{t_2}^2] = R_X(t_2 + h_2, t_2 + h_2) + \\ &+ R_X(t_2, t_2) - 2R_X(t_2 + h_2, t_2) \xrightarrow{h_2 \rightarrow 0} 0. \end{aligned}$$

Следовательно, $R_X(t_1 + h_1, t_2 + h_2) \xrightarrow{h_1, h_2 \rightarrow 0} R_X(t_1, t_2)$ и $R_X(t_1, t_2)$ непрерывна везде. \square

Теперь посмотрим на три класса случайных процессов: IID, SSS и WSS. Есть ли между ними какая-либо связь? Есть. Начнём с очевидной цепочки вложений: $\text{IID} \subseteq \text{SSS} \subseteq \text{WSS}$. Хотя второе вложение не совсем корректно — не все сильно стационарные процессы являются процессами второго порядка. Если добавить это требование, то вложение станет корректным. Теперь покажем, что все вложения строгие.

- Начнём с $\text{SSS} \setminus \text{IID}$. Возьмём случайную последовательность $X = (X_t)_{t \in T}$, устроенную следующим образом: для всех t $X_t = \xi$, где ξ — это какая-то фиксированная случайная величина. Она очевидно является стационарной в сильном смысле и все её сечения одинаково распределены, но она не задаёт последовательность независимых случайных величин.
- Теперь посмотрим на $\text{WSS} \setminus \text{SSS}$. Суть примера в том, что мы будем брать разные распределения, у которых совпадают матожидание и дисперсия. Например, пусть

$X = (X_t)_{t \geq 0}$ — случайная последовательность независимых случайных величин такая, что $X_{2n} \sim \text{Bern}(p)$, а $X_{2n+1} \sim \mathcal{N}(p, p(1-p))$. Понятно, что ни о каком равенстве распределений и речи быть не может, а вот слабая стационарность выполнена (почему?).

- Приведём ещё один пример процесса из $\text{SSS} \setminus \text{IID}$. Пусть $\{X_n\}_{n=1}^\infty$ — последовательность iid случайных величин. Построим по ней новую последовательность $\{Y_n\}_{n=1}^\infty$ по правилу $Y_n = X_n + X_{n+1}$. Понятно, что полученная последовательность не будет состоять из независимых случайных величин, но она будет сильно стационарной.

2 Генерирование реализаций случайных процессов

Теперь посмотрим, как симулировать различные процессы. Начнём с самого простого — с пуассоновского потока.

2.1 Генерирование пуассоновских случайных процессов

2.1.1 Однородный пуассоновский поток событий

Для тех, кто забыл — определение пуассоновского потока дано в примере ???. Единственная сложность в генерации реализации состоит в том, что нужно уметь генерировать случайные величины из экспоненциального распределения. Но мы можем свободно генерировать случайные величины из $U(0, 1)$. Как получить из него экспоненциальное распределение? Для этого докажем одно утверждение:

Лемма (Метод обратного преобразования). Пусть X — случайная величина с неубывающей функцией распределения $F : \mathbb{R} \mapsto [0, 1]$. Введём обратную функцию $F^{-1} : [0, 1] \mapsto \mathbb{R}$ следующим образом: $F^{-1}(u) = \inf\{x \in \mathbb{R} : F(x) \geq u\}$. Тогда, если $U \sim U(0, 1)$, то $F^{-1}(U)$ имеет функцию распределения F .

Доказательство. Действительно, $P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x)$. □

Теперь покажем, как генерировать случайные величины из распределения $\text{Exp}(\lambda)$. Рассмотрим функцию распределения:

$$F(x) = 1 - e^{-\lambda x} \implies x = -\frac{1}{\lambda} \ln(1 - F(x)) \implies F^{-1}(x) = -\frac{1}{\lambda} \ln(1 - x).$$

Тогда по методу обратного преобразования $-\ln(1 - U)/\lambda$ будет иметь распределение $\text{Exp}(\lambda)$. Теперь заметим, что $1 - U \stackrel{d}{=} U$. Тогда получаем, что $-\frac{1}{\lambda} \ln U$ будет иметь нужное распределение.

Теперь несложно написать алгоритм генерации реализации однородного пуассоновского потока.

Алгоритм 1 Алгоритм генерации реализации однородного пуассоновского потока

Вход: Интенсивность λ , максимальное время T .

- 1: $t \leftarrow 0, I \leftarrow 0, S \leftarrow \emptyset$
 - 2: сгенерировать $U \sim U(0, 1)$
 - 3: $t \leftarrow t - \ln(U)/\lambda$
-

```

4: while  $t \leq T$  do
5:    $I \leftarrow I + 1, S(I) \leftarrow t$ 
6:   сгенерировать  $U \sim U(0, 1)$ 
7:    $t \leftarrow t - \ln(U)/\lambda$ 

```




Рис. 1: Пример реализации пуассоновского потока с параметрами $T = 1000$, $\lambda = 0.02$

2.1.2 Неоднородный пуассоновский поток событий

Ранее мы смотрели на однородный пуассоновский процесс. Однородный он по той простой причине, что его интенсивность постоянна. Теперь скажем, что λ — это какая-то функция от t . В таком случае получим *неоднородный пуассоновский поток*. Определяется он почти так же, как и **однородный**, только немного изменяется третье свойство:

$$X_t - X_s \sim \text{Pois} \left(\int_s^t \lambda(x) dx \right).$$

Но считать интегралы не очень приятно. Можно ли обойтись без них? Можно. Рассмотрим однородный пуассоновский поток N_t с интенсивностью λ . Пусть событие, появляющееся в момент времени t “засчитывается” с некоторой вероятностью $p(t)$, то есть

$$P(N_t = N_{t-\varepsilon} + 1) = p(t), \quad P(N_t = N_{t-\varepsilon}) = 1 - p(t)$$

Оказывается, что N_t — неоднородный пуассоновский поток событий с интенсивностью $\lambda(t) = \lambda p(t)$. Этот результат называется *теоремой Льюиса-Шедлера*.

Пусть $\tilde{\lambda} = \max_{t \in [0, T]} \lambda(t)$. Тогда алгоритм будет выглядеть так:

Алгоритм 2 Алгоритм генерации реализации неоднородного пуассоновского потока

Вход: Интенсивность $\lambda(t)$, максимальное время T .

```

1:  $t \leftarrow 0, I \leftarrow 0, S \leftarrow \emptyset$ ,
2: сгенерировать  $U_1 \sim U(0, 1)$ 
3:  $t \leftarrow t - \ln(U_1)/\tilde{\lambda}$ 
4: while  $t \leq T$  do
5:   сгенерировать  $U_2 \sim U(0, 1)$ 
6:   if  $U_2 \leq \lambda(t)/\tilde{\lambda}$  then
7:      $I \leftarrow I + 1, S(I) \leftarrow t$ 
8:   сгенерировать  $U_1 \sim U(0, 1)$ 
9:    $t \leftarrow t - \ln(U_1)/\tilde{\lambda}$ 

```




Рис. 2: Пример реализации неоднородного пуассоновского потока с параметрами $T = 1000$, $\lambda(t) = (\sin(t/100) + 1)/100$.

2.2 Метод стохастического интегрирования

Как известно, дифференциальные уравнения описывают очень многое. Но, оказывается, их можно приспособить и для описания случайных процессов. Основное отличие состоит в том, что в данном случае функция, относительно которой решается уравнение, является случайной величиной. Такие дифференциальные уравнения называют *стохастическими*.

Оказывается, что многие процессы, которые изучаются на практике, “управляются” броуновским движением. Однако есть проблема: траектории винеровского процесса нигде не дифференцируемы почти наверное. Поэтому манипулирование с процессами такого типа потребовало создания собственного исчисления, называемого теорией *стохастических интегралов*. Дадим определение:

Определение 12. Пусть $T = \{t_k\}_{k=0}^n$ — некоторое разбиение отрезка $[0, t]$. Далее, выберем точки $\tau = \{\tau_k\}_{k=1}^n$ по правилу $\tau_k \in [t_{k-1}, t_k]$. Составим по этому разбиению интегральную сумму:

$$S_n = \sum_{k=1}^n b(\tau_k)(B_{t_k} - B_{t_{k-1}})$$

Стохастическим интегралом от неслучайной функции $b(t)$ по броуновскому движению $B = (B_t)_{t \geq 0}$ называют предел интегральных сумм при диаметре разбиения, стремящемся к нулю.³

$$\int_0^t b(x) dB_x = \lim_{\Delta T \rightarrow 0} S_n$$

Примечание. Не стоит забывать, что $B_{t_i} - B_{t_{i-1}} \sim \mathcal{N}(0, t_i - t_{i-1})$. Это поможет при симуляции процесса.

Многие стохастические процессы могут быть записаны в виде

$$X_t = \int_0^t a(x) dx + \int_0^t b(x) dB_x,$$

³Вопрос о том, почему этот предел вообще существует и каким образом последовательность частичных сумм сходится к нему, оставим за кадром.

где $a(x)$ и $b(x)$ — некоторые неслучайные функции. Это же выражение можно записать в дифференциалах: $dX_t = a(t) dt + b(t) dB_t$.

Как использовать этот метод? Примерно так же, как и в численном интегрировании: заменить дифференциал на малое изменение и суммировать.

$$X_{t+\varepsilon} - X_t \approx a(t)\varepsilon + b(t)(B_{t+\varepsilon} - B_t).$$

2.3 Метод гауссовских векторов

Если нужно сгенерировать не слишком большую реализацию гауссовского процесса, то ситуация становится несколько проще. Как известно, у них все конечномерные функции распределения являются гауссовскими, поэтому реализация будет являться гауссовским вектором. Далее, нам известны математическое ожидание и ковариационная функция процесса. Из этого можно вытащить математическое ожидание и матрицу ковариаций нужного вектора.

Но есть проблема: как генерировать случайный гауссовский вектор с заданным распределением? Сходу это сделать не получится. Для этого проведём одно рассуждение.

Допустим, что вектор одномерный, то есть это просто случайная величина $\xi \sim \mathcal{N}(\mu, \sigma^2)$. Как из стандартного нормального распределения получить нужное распределение? Легко: $\xi \stackrel{d}{=} \mu + \sigma\eta$, где $\eta \sim \mathcal{N}(0, 1)$.

Оказывается, что для общего случая верно нечто похожее. Пусть μ — некоторый фиксированный вектор, Σ — квадратная матрица, а $\xi \sim \mathcal{N}(\mu, \Sigma)$. Какое распределение будет у случайного вектора $\eta = \mu + \Sigma\xi$? Так как преобразование линейно, то это гауссовский вектор с параметрами

$$\begin{aligned} \mathbb{E}[\eta] &= \mathbb{E}[\mu + \Sigma\xi] = \mathbb{E}[\mu] + \Sigma \mathbb{E}[\xi] = \mu \\ \mathbb{D}[\eta] &= \mathbb{E}[\Sigma\xi(\Sigma\xi)^\top] = \Sigma \mathbb{E}[\xi\xi^\top] \Sigma^\top = \Sigma\Sigma^\top. \end{aligned}$$

Теперь вспомним один факт из линейной алгебры.

Теорема 6 (Разложение Холецкого). Пусть Σ — неотрицательно определённая симметричная матрица. Тогда существует нижнетреугольная матрица C с неотрицательными членами на диагонали такая, что $\Sigma = CC^\top$. Если же Σ положительно определена, то все члены C на диагонали строго положительны.

Выпишем формулы для вычисления матрицы C :

$$C_{kk} = \sqrt{\Sigma_{kk} - \sum_{j=1}^{k-1} C_{kj}^2}, \quad C_{ij} = \frac{1}{C_{jj}} \left(\Sigma_{ij} - \sum_{k=1}^{j-1} C_{ik} C_{jk} \right)$$

Отсюда понятно, как генерировать гауссовский вектор с заданным распределением $\mathcal{N}(\mu, \Sigma)$. Для этого мы независимо генерируем n случайных величин с распределением $\mathcal{N}(0, 1)$ (это можно сделать с помощью того же преобразования Бокса-Мюллера) и получаем гауссовский вектор ξ . Далее, берём матрицу C из разложения Холецкого и строим новый вектор $\eta = \mu + C\xi$. Полученный вектор будет иметь нужное распределение.

2.4 Генерирование гауссовских случайных процессов

2.4.1 Винеровский процесс

Сначала разберёмся, как генерировать его с помощью гауссовских векторов. Для этого достаточно сгенерировать матрицу ковариаций и вектор матожиданий. Как известно, $m(t) = 0$, а $R(s, t) = \min(s, t)$.

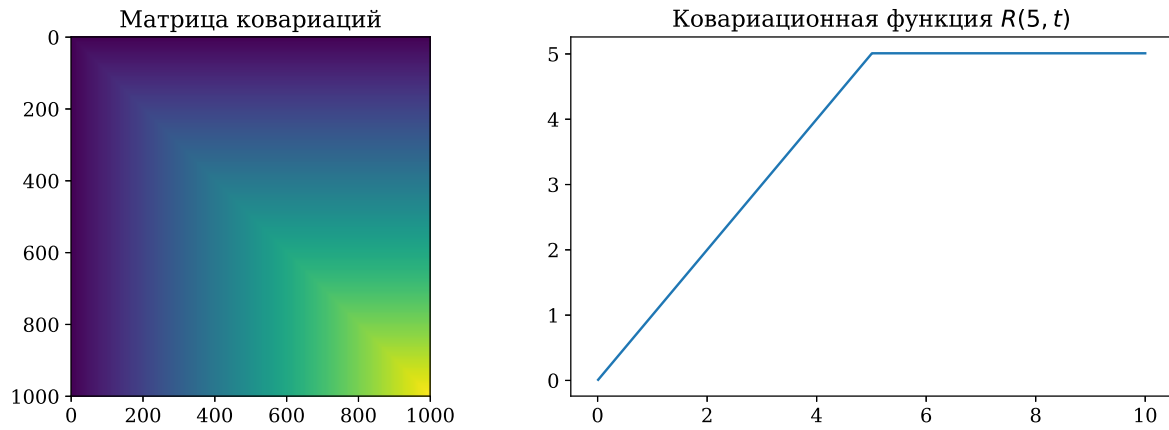


Рис. 3: Визуализация матрицы ковариаций и $R(5, t)$ для $t \in (0, 10)$.

Интереснее генерация с помощью стохастического интегрирования. Хотя и данном случае всё достаточно очевидно: B_t можно приблизить суммой достаточно большого числа нормальных случайных величин:

$$B_t = \int_0^t dB_x \approx \sum_{k=1}^N (B_{t_k} - B_{t_{k-1}}).$$

Для примера посмотрим на первые десять секунд. Для этого разобьём отрезок $[0, 10]$ на 1000 равных кусков и посчитаем эту сумму. Это даст приемлемую точность.




Рис. 4: Пример реализации первых десяти секунд броуновского движения.

2.4.2 Процесс Орнштейна-Уленбека

Ранее мы обсуждали процесс Орнштейна-Уленбека. Однако на самом деле он определяется немного по-другому:

Определение 13. Случайный процесс $X = (X_t)_{t \geq 0}$, удовлетворяющий стохастическому дифференциальному уравнению

$$dX_t = \theta(\mu - X_t) dt + \sigma dB_t, \quad X_0 = x_0,$$

называется процессом Орнштейна-Уленбека.

Для того, чтобы получить ранее описанный процесс, нужно подставить $\sigma = \sqrt{2}$, $\theta = 1$, $\mu = 0$ и $x_0 = 0$. Для генерации его реализации с помощью гауссовского вектора достаточно вспомнить, что $E[X_t] = 0$ и $\text{cov}(X_t, X_s) = e^{-|t-s|}$.

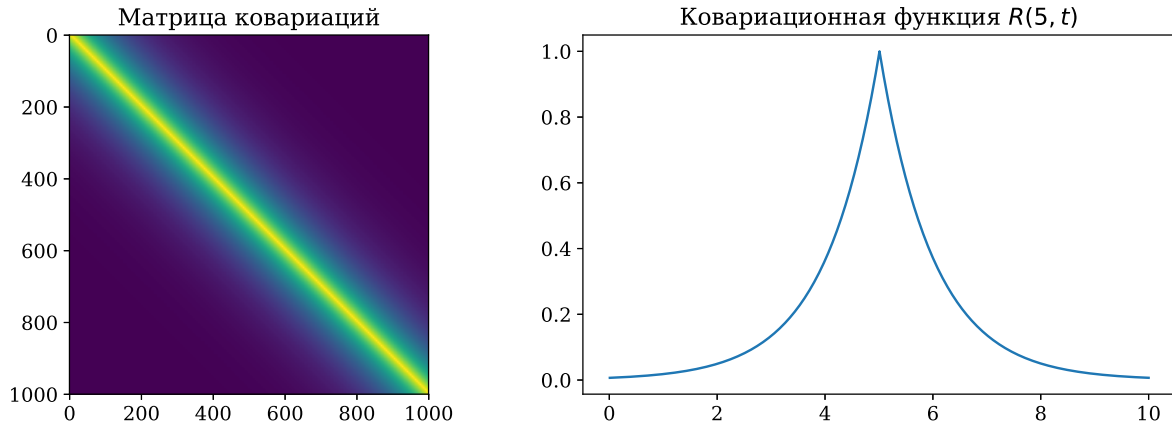


Рис. 5: Визуализация матрицы ковариаций и $R(5, t)$ для $t \in (0, 10)$.

Разностная схема устроена следующим образом:

$$X_{t_{i+1}} - X_{t_i} = \theta(\mu - X_{t_i})(t_{i+1} - t_i) + \sigma(B_{t_{i+1}} - B_{t_i}).$$




Рис. 6: Пример реализации первых десяти секунд процесса Орнштейна-Уленбека с параметрами $x_0 = 2$, $\sigma = 0.1$, $\mu = 1.2$, $\theta = 1$.

2.4.3 Фрактальное броуновское движение

Напоследок рассмотрим ещё один случайный процесс, называемый *фрактальным броуновским движением*.

Определение 14. Фрактальное броуновское движение с параметром Хёрста $H \in (0, 1)$ — это гауссовский случайный процесс с непрерывным временем $B^H = (B_t^H)_{t \in [0, T]}$, удовлетворяющий следующим условиям:

- $B_0^H = 0$ почти наверное,
- $E[B_t^H] = 0$ для всех $t \in [0, T]$,
- $\text{cov}(B_t^H, B_s^H) = \frac{1}{2}(|t|^{2H} + |s|^{2H} - |t - s|^{2H})$.

Оказывается, что если подставить $H = 1/2$, то получится обычное броуновское движение.⁴ В остальных случаях получается некоторый гауссовский процесс.

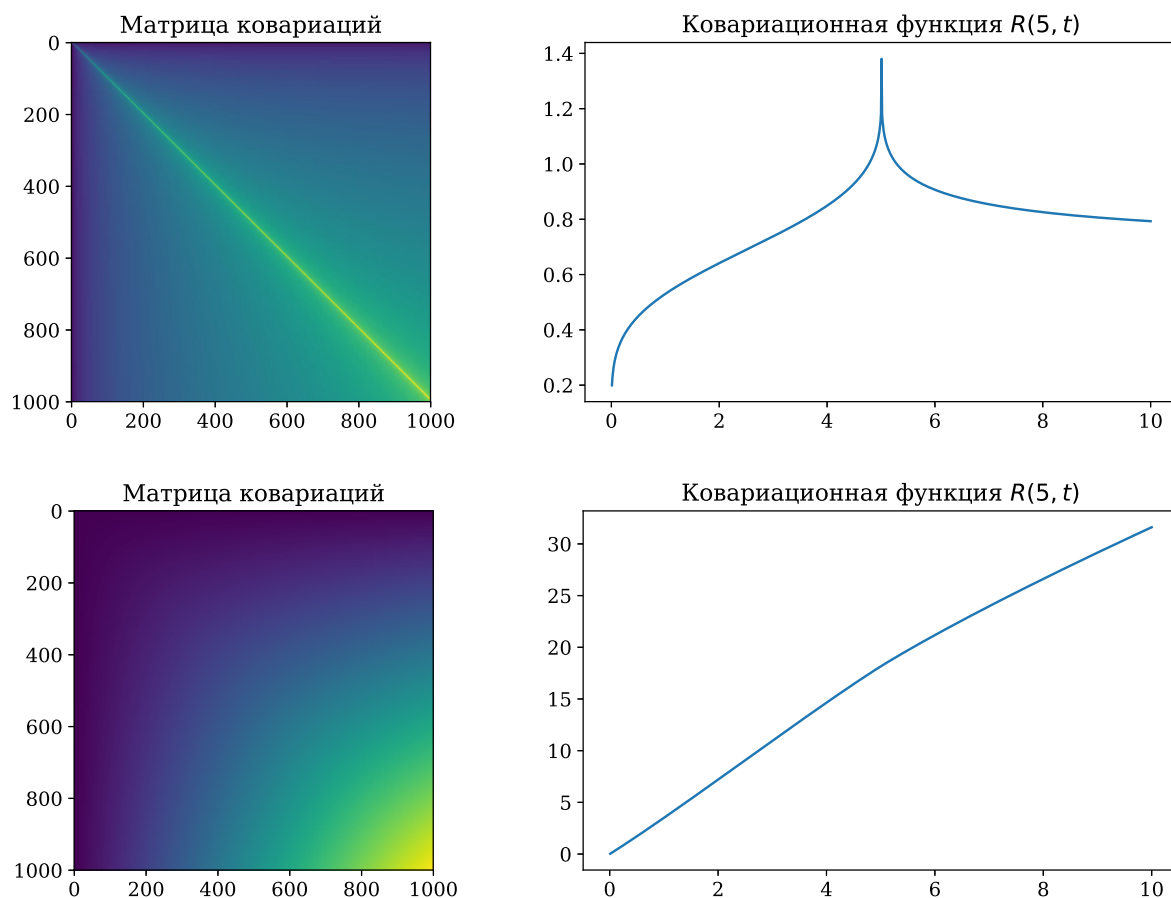


Рис. 7: Визуализация матрицы ковариаций и $R(5, t)$ для $t \in (0, 10)$ при $H = 0.1$ и $H = 0.9$.

После того, как была получена матрица ковариаций, дело остаётся за малым: получить нужную реализацию с помощью разложения Холецкого. Я не буду описывать технические детали, ибо они и так очевидны. Теперь посмотрим, как себя ведут траектории в зависимости от параметра Хёрста.




Рис. 8: Пример реализаций первых десяти секунд фрактального броуновского движения при разных параметрах Хёрста.

⁴Возникает вопрос о том, что делать с независимостью приращений. Но есть теорема, которая гласит, что фрактальное броуновское движение имеет независимые приращения только при $H = 1/2$.